

Wie hoch ist die **Entropie** einer Zufallsvariablen mit einer uniformen Verteilung über 4 Werte (also wenn alle Werte die gleiche Wahrscheinlichkeit haben)?

Die **Entropie** misst, wieviel Information ein Zufallsereignis im Mittel enthält.

Entropie einer Zufallsvariablen X mit der Verteilungsfunktion $p(x)$:

$$H(X) = H(p) = - \sum_{x \in X} p(x) \log_2 p(x) = E\left(\log_2 \frac{1}{p(x)}\right)$$

Antwort

Bei einer uniformen Verteilung über 4 Werte hat jeder Wert die Wahrscheinlichkeit $1/4$.

Die Entropie beträgt daher $-4 * 0.25 * \log_2(1/4) = \log_2(4) = 2$ Bit

Berechnung

Die Zufallsvariable X hat 4 Werte, jeweils mit $p(x) = 1/4$

$$\begin{aligned} H(X) &= - \left[\frac{1}{4} * \log_2 \left(\frac{1}{4} \right) + \frac{1}{4} * \log_2 \left(\frac{1}{4} \right) + \frac{1}{4} * \log_2 \left(\frac{1}{4} \right) + \frac{1}{4} * \log_2 \left(\frac{1}{4} \right) \right] \\ &= - \left[4 * \frac{1}{4} * \log_2 \left(\frac{1}{4} \right) \right] \\ &= - 1 * \log_2 \left(\frac{1}{4} \right) \\ &= - \log_2 \left(\frac{1}{4} \right) \\ &= \log_2 \left(\frac{1}{(1/4)} \right) \\ &= \log_2 (4) \end{aligned}$$

$$\log \left(\frac{1}{a} \right) = -\log a$$

9. **$\log (1/a) = -\log a$** means that the logarithm of 1 divided by some number is equal to the negative logarithm of that number. (This is the exactly the opposite of the rule governing exponents where a number raised to a negative number is equal to 1 divided by that number raised to that power.)

For example:

$$\log (1/2) = -\log 2 = -0.301$$

$$\log (1/3) = -\log 3 = -0.477$$

$$\ln (1/2) = -\ln 2 = -0.693$$

$$\ln (1/3) = -\ln 3 = -1.099$$



ref: <http://www.mclph.umn.edu/mathrefresh/logs5.html#:~:text=9.,number%20raised%20to%20that%20power.>)

Wie hoch ist die Entropie (einer Zufallsvariablen mit einer uniformen Verteilung über 4 Werte), wenn einer der Werte die Wahrscheinlichkeit 1 besitzt?

$$H(X) = H(p) = - \sum_{x \in X} p(x) \log_2 p(x)$$

Antwort

0

Berechnung:

Wenn eine $p(x)$ den Wert 1 hat, dann sind die anderen $p(x)$ null. Wenn man die Werte in der Formel von Entropie einsetzt, dann bekommt man null als Ergebnis.

$$H(X) = - [1 * \log_2(1) + 0 * \log_2(0) + 0 * \log_2(0) + 0 * \log_2(0)]$$

$$1 * \log_2(1) = 0 \text{ (wegen } \log_2(1) = 0 \text{)}$$

Bei $0 * \log_2(0)$ wird es wie folgt berechnet.

$\log(0)$ ist minus unendlich. Die Frage ist also, welches Resultat 0 mal unendlich ergibt. Hierzu muss der Limes für $x \rightarrow 0$ von $-x \log(x)$ berechnet werden. Da x schneller gegen 0 geht, als $-\log(x)$ gegen unendlich geht, ist das Ergebnis 0. Beispiele

$$x * -\log(x)$$

$$1/2 * 1 = 1/2$$

$$1/4 * 2 = 1/2$$

$$1/8 * 3 = 3/8$$

$$1/64 * 6 = 1/6$$

$$1/1024 * 10 = 1/102.4$$

Geben Sie die Formel für die Berechnung des Erwartungswertes der Funktion $-\log p(x)$ für die Zufallsvariable X an.

Antwort: Die Erwartungswert von $-\log p(x) = -\sum_{x \in X} p(x) \log_2 p(x)$ # es ist gleich die Entropie von X

Berechnung:

Erwartungswert einer Funktion f :

$$E(f(X)) = \sum_x p(x) f(x)$$

$E(f(X))$ ist die Summe über x von $p(x) * f(x)$, wobei x die einzelnen Werte von X sind.

$f(X)$ ist eine Funktion, die eine Zufallsvariable X als Argument nimmt (und X kann mehrere Werte x annimmt).

Wir betrachten $-\log p(x)$ als eine Funktion, die einen Wert x der Zufallsvariable X als Argument nimmt.

Also, $f(x)$ in der Formel ist hier $-\log p(x)$

$p(x)$ ist die WK der einzelnen Werte x aus X

$$\begin{aligned} E(-\log p(x)) &= \text{SUM}_x p(x) * -\log p(x) \quad \# \text{ diese Zeile ist als Antwort auch gültig} \\ &= \text{SUM}_x p(x) * (-1) * \log p(x) \\ &= (-1) \text{SUM}_x p(x) * \log p(x) \quad \# -1 \text{ aus der Summe nehmen} \\ &= -\text{SUM}_x p(x) * \log p(x) \quad \# \text{ so erhalten wir die Entropie-Formel von } X \end{aligned}$$

$$\sum_{k=1}^n ck = c \sum_{k=1}^n k,$$

Aufgabe 4) Angenommen der Satz “I can can a can” soll mit einem Bigramm-Tagger und dem Viterbi-Algorithmus mit Wortarten annotiert werden und das Tagset umfasst nur die Tags PRO, D, N, und V. Bei jedem Wort soll jedes Tag erlaubt sein.

- 1 Wie wird die Tabelle mit den Viterbiwahrscheinlichkeiten zu Beginn initialisiert?
- 2 Wie berechnet der Algorithmus die Viterbi-Wahrscheinlichkeit des Tags D an Position 4, also beim Wort “a”? (Geben Sie den richtigen Ausdruck für diesen konkreten Fall ohne Variablen an.)

Viterbi-Algorithmus (Bigramm-Tagger)

			k-1	k		
“ “	I	can	can	a	can	“ “
<s>	PRO	PRO	PRO	PRO	PRO	<s>
	D	D	D	D	D	
	N	N	N	N	N	
	V	V	V	V	V	

1. Initialisierung: $\delta_t(0) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$

2. Berechnung: (für $0 < k \leq n + 1$)

$$\delta_t(k) = \max_{t'} \delta_{t'}(k-1) p(t|t') p(w_k|t)$$

1. initialisierung: $\text{vit}(\langle s \rangle, 0) = 1$

2. $\text{vit}(\text{D}, 4) = \max [\text{vit}(\text{PRO}, 3) * p(\text{D} | \text{PRO}) * p(\text{a} | \text{D}),$
 $\text{vit}(\text{D}, 3) * p(\text{D} | \text{D}) * p(\text{a} | \text{D}),$
 $\text{vit}(\text{N}, 3) * p(\text{D} | \text{N}) * p(\text{a} | \text{D}),$
 $\text{vit}(\text{V}, 3) * p(\text{D} | \text{V}) * p(\text{a} | \text{D})]$

Aufgabe 4) Angenommen der Satz "I can can a can" soll mit einem Bigramm-Tagger und dem Viterbi-Algorithmus mit Wortarten annotiert werden und das Tagset umfasst nur die Tags PRO, D, N, und V. Bei jedem Wort soll jedes Tag erlaubt sein.

Trigramm-Tagger

1 Wie wird die Tabelle mit den Viterbiwahrscheinlichkeiten zu Beginn initialisiert?

PRO,D

2 Wie berechnet der Algorithmus die Viterbi-Wahrscheinlichkeit des Tags ~~D~~ an Position 4, also beim Wort " " (Geben Sie den richtigen Ausdruck für diesen konkreten Fall ohne Variablen an.) (3 Punkte)

				k-1	k				k= n+2
" "	" "	I	can	can	a	can	" "	" "	
<s>	<s>	PRO	PRO	PRO	PRO	PRO	<s>	<s>	
		D	D	D	D	D			
		N	N	N	N	N			
		V	V	V	V	V			

1. Initialisierung: $\delta_{t',t}(0) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \text{ und } t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$

2. Berechnung: (für $0 < k \leq n+2$)

$$\delta_{t',t}(k) = \max_{t''} \delta_{t'',t'}(k-1) p(t|t'',t') p(w_k|t)$$

1. initialisierung: $\text{vit}(\langle s \rangle, \langle s \rangle, 0) = 1$

2. $\text{vit}(\text{PRO}, \text{D}, 4) = \max [\text{vit}(\text{PRO}, \text{PRO}, 3) * p(\text{D} | \text{PRO}, \text{PRO}) * p(\text{a} | \text{D}),$
 $\text{vit}(\text{D}, \text{PRO}, 3) * p(\text{D} | \text{D}, \text{PRO}) * p(\text{a} | \text{D}),$
 $\text{vit}(\text{N}, \text{PRO}, 3) * p(\text{D} | \text{N}, \text{PRO}) * p(\text{a} | \text{D}),$
 $\text{vit}(\text{V}, \text{PRO}, 3) * p(\text{D} | \text{V}, \text{PRO}) * p(\text{a} | \text{D})]$

Aufgabe 4) Angenommen der Satz "I can can a can" soll mit einem Bigramm-Tagger und dem Viterbi-Algorithmus mit Wortarten annotiert werden und das Tagset umfasst nur die Tags PRO, D, N, und V. Bei jedem Wort soll jedes Tag erlaubt sein.

Trigramm-Tagger

1 Wie wird die Tabelle mit den Viterbiwahrscheinlichkeiten zu Beginn initialisiert?

<S>, <S>

2 Wie berechnet der Algorithmus die Viterbi-Wahrscheinlichkeit des Tags ~~D~~ an Position $k=n+2$ beim Wort "a"? (Geben Sie den richtigen Ausdruck für diesen konkreten Fall ohne Variablen an.) (3 Punkte)

						k-1	k = n+2	
" "	" "	I	can	can	a	can	" "	" "
<S>	<S>	PRO	PRO	PRO	PRO	PRO	<S>	<S>
		D	D	D	D	D		
		N	N	N	N	N	t'	t
		V	V	V	V	V		
						t''		

1. Initialisierung: $\delta_{t',t}(0) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \text{ und } t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$

2. Berechnung: (für $0 < k \leq n+2$)

$$\delta_{t',t}(k) = \max_{t''} \delta_{t'',t'}(k-1) p(t|t'', t') p(w_k|t)$$

1. initialisierung: $\text{vit}(\langle s \rangle, \langle s \rangle, 0) = 1$

2. $\text{vit}(\langle s \rangle, \langle s \rangle, 7) = \max [\text{vit}(\text{PRO}, \langle s \rangle, 6) * p(\langle s \rangle | \text{PRO}, \langle s \rangle) * p(" " | \langle s \rangle),$
 $\text{vit}(\text{D}, \langle s \rangle, 6) * p(\langle s \rangle | \text{D}, \langle s \rangle) * p(" " | \langle s \rangle),$
 $\text{vit}(\text{N}, \langle s \rangle, 6) * p(\langle s \rangle | \text{N}, \langle s \rangle) * p(" " | \langle s \rangle),$
 $\text{vit}(\text{V}, \langle s \rangle, 6) * p(\langle s \rangle | \text{V}, \langle s \rangle) * p(" " | \langle s \rangle)]$

CRF Viterbi

Merkmale:



- Tag-Wort-Merkmale Beispiel: TW-INJ-Hallo mit Gewicht 0.7
- Tag-Tag-Merkmale Beispiel: TT- $\langle s \rangle$ -INJ mit Gewicht 1.3

Berechnung eines **Merkmalsvektors**

$$f(\langle s \rangle, \text{INJ}, (\text{Hallo}), 1) = \{(\text{"TT-}\langle s \rangle\text{-INJ"}, 1), (\text{"TW-INJ-Hallo"}, 1)\}$$

Berechnung eines **lokalen Scores**

$$s(\langle s \rangle, \text{INJ}, (\text{Hallo}), 1) = 1.3 * 1 + 0.7 * 1 = 2.0$$

Berechnung der **Viterbi-Scores** $\delta(i, t)$:

$$\delta(0, \langle s \rangle) = \log(1) = 0$$

$$\delta(1, \text{INJ}) = \max_{t \in \{\langle s \rangle\}} \delta(0, t) + s(t, \text{INJ}, (\text{Hallo}), 1) = 0 + 2.0$$

$$\delta(1, XY) = \max_{t \in \{\langle s \rangle\}} \delta(0, t) + s(t, XY, (\text{Hallo}), 1) = 0 + \dots$$

$$\delta(2, \langle s \rangle) = \max_{t \in \{\text{INJ}, XY\}} \delta(1, t) + s(t, \langle s \rangle, (\text{Hallo}), 2) = \dots$$

Übung: Berechne vit(D,4) für Wort a (Viterbi, Bigramm, CRF)

Alternativ mit logarithmierten Werten:

87

$$s(t', t, w_1^n, i) = \theta \cdot f(t', t, w_1^n, i)$$

$$\delta_t(0) = 0 \text{ falls } t = \langle s \rangle \text{ sonst } -\infty$$

$$\delta_t(i) = \max_{t'} \delta_{t'}(i-1) + s(t', t, w_1^n, i) \quad \text{für } 1 \leq i \leq n+1$$

$$\psi_t(i) = \arg \max_{t'} \delta_{t'}(i-1) + s(t', t, w_1^n, i) \quad \text{für } 1 \leq i \leq n+1$$

			i-1	i		
" "	I	can	can	a	can	" "
<s>	PRO	PRO	PRO	PRO	PRO	<s>
	D	D	D	D	D	
	N	N	N	N	N	
	V	V	V	V	V	

1. initialisierung: vit(<s>, 0) = 0

2. vit(D,4) = max [vit(PRO,3) + s(PRO, D, "I can can a can", 4),
 vit(D,3) + s(D, D, "I can can a can", 4),
 vit(N,3) + s(N, D, "I can can a can", 4),
 vit(V,3) + s(V, D, "I can can a can", 4)]

Falls Merkmal = tag-tag, tag-wort (wie bei HMM), haben wir f (PRO, D, "I can can a can", 4) = {"TT-PRO-D": 1, "TW-D-a": 1 }

s(PRO, D, "I can can a can", 4) = gewicht("TT-PRO-D") * 1 + gewicht("TW-D-a") * 1

falls gewichte(PRO, D, "I can can a can", 4) = {"TT-PRO-D": 0.3, "TW-D-a": 2.4 }, dann haben wir

s(PRO, D, "I can can a can", 4) = 0.3 * 1 + 2.4 * 1 oder einfach 0.3 + 2.4

Übung: Berechne **vit(PRO, D,4)** (Viterbi, Trigramm, CRF)

note: hier ist die Bigramm
Formel von CRF-Viterbi
(steht nur als Referenz hier)

1. Initialisierung: $\delta_{t',t}(0) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \text{ und } t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$

2. Berechnung: (für $0 < k \leq n + 2$)

$$\delta_{t',t}(k) = \max_{t''} \delta_{t'',t'}(k-1) \overset{+ s(t'', t', t, w_{1..n}, i)}{p(t|t'', t')} p(w_k|t)$$

$$s(t', t, w_1^n, i) = \theta \cdot f(t', t, w_1^n, i)$$

$$\delta_t(0) = 0 \text{ falls } t = \langle s \rangle \text{ sonst } -\infty$$

$$\delta_t(i) = \max_{t'} \delta_{t'}(i-1) + s(t', t, w_1^n, i) \quad \text{für } 1 \leq i \leq n+1$$

				k-1	k				
" "	" "	I	can	can	a	can	" "	" "	
<s>	<s>	PRO	PRO	PRO	t'	PRO	PRO	<s>	<s>
		D	D	D	t	D	D		
		N	N	N		N	N		
		V	V	V		V	V		

1. initialisierung: $\text{vit}(\langle s \rangle, 0) = 0$

2. $\text{vit}(\text{PRO}, \text{D}, 4) = \max [$

- $\text{vit}(\text{PRO}, \text{PRO}, 3) + s(\text{PRO}, \text{PRO}, \text{D}, \text{"I can can a can"}, 4),$
- $\text{vit}(\text{D}, \text{PRO}, 3) + s(\text{D}, \text{PRO}, \text{D}, \text{"I can can a can"}, 4),$
- $\text{vit}(\text{N}, \text{PRO}, 3) + s(\text{N}, \text{PRO}, \text{D}, \text{"I can can a can"}, 4),$
- $\text{vit}(\text{V}, \text{PRO}, 3) + s(\text{V}, \text{PRO}, \text{D}, \text{"I can can a can"}, 4)]$

Merkmale kann z.B. wie folg definieren: "TTT- T1-T2-T3", "TW-T3-W3" , mit T3 entspricht t , T2 entspricht t', und T1 entspricht t''

Beispiel:

$$f(\text{PRO}, \text{PRO}, \text{D}, \text{"I can can a can"}, 4) = \{ \text{"TTT-PRO-PRO-D": 1, "TW-D-a": 1 } \}$$

Andere mögliche Merkmale

- Für jede Wortposition i wird ein Merkmalsvektor $f(t_{i-k}^i, w_1^n, i)$ extrahiert.
 - ▶ lexikalische Merkmale (ohne Nachbartag-Information)
Wort+Tag, Wortsuffix+Tag, Wort"shape"+Tag, voriges Wort+Tag,
nächstes Wort+Wort+Tag, Wort+Tag im Lexikon
 - ▶ Kontext-Merkmale (mit Nachbartag-Information)
voriges Tag+Tag, letzte2Tags+Tag, voriges Tag+Wort+Tag

Übung: Trigramm-Forward-Wk

1. initialisiere die Forward WK nach der Formel

2. Berechne Forward-WK für PRO,D an Position 4 für die Wortfolge “I can can a can”. Alle Wörter haben die gleichen möglichen Tags: PRO,D, N, V.

Definition der Forward-Wahrscheinlichkeiten $\alpha_{t',t}(k)$

7

$$\alpha_{t',t}(0) = \begin{cases} 1 & \text{falls } t = t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\alpha_{t',t}(k) = \sum_{t'' \in T} \alpha_{t'',t'}(k-1) p(t|t'',t') p(w_k|t) \quad \text{für } 1 \leq k \leq \mathbf{n} + \mathbf{2}$$

I	can	can	a	can
PRO	PRO	PRO	PRO	PRO
D	D	D	D	D
N	N	N	N	N
V	V	V	V	V

Übung (Lösung):

1. initialisierung

2. Berechne Forward-WK für PRO,D an Position 4 für die Wortfolge "I can can a can". Alle Wörter haben die gleichen möglichen Tags: PRO,D, N, V.

Definition der Forward-Wahrscheinlichkeiten $\alpha_{t',t}(k)$

↗

$$\alpha_{t',t}(0) = \begin{cases} 1 & \text{falls } t = t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\alpha_{t',t}(k) = \sum_{t'' \in T} \alpha_{t'',t'}(k-1) p(t|t'',t') p(w_k|t) \quad \text{für } 1 \leq k \leq \mathbf{n} + 2$$

" "	" "	I	can	can	a	can	" "	" "
<s>	<s>	PRO	PRO	PRO	PRO	PRO	<s>	<s>
		D	D	D	D	D		
		N	N	N	N	N		
		V	V	V	V	V		

1. $\text{fw}(\langle s \rangle, \langle s \rangle, 0) = 1$

2. $\text{fw}(\text{PRO}, \text{D}, 4) = \text{fw}(\text{PRO}, \text{PRO}, 3) * p(\text{D} | \text{PRO}, \text{PRO}) * p(\text{a} | \text{D}) +$
 $\text{fw}(\text{D}, \text{PRO}, 3) * p(\text{D} | \text{D}, \text{PRO}) * p(\text{a} | \text{D}) +$
 $\text{fw}(\text{N}, \text{PRO}, 3) * p(\text{D} | \text{N}, \text{PRO}) * p(\text{a} | \text{D}) +$
 $\text{fw}(\text{V}, \text{PRO}, 3) * p(\text{D} | \text{V}, \text{PRO}) * p(\text{a} | \text{D})$

Übung: Trigramm-Backward-Wk

Definition der Backward-Wahrscheinlichkeiten $\beta_{t'',t'}(k)$:

$$\beta_{t'',t'}(n+2) = \begin{cases} 1 & \text{falls } t'' = t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\beta_{t'',t'}(k) = \sum_{t \in T} p(t|t'',t') p(w_{k+1}|t) \beta_{t',t}(k+1) \quad \text{für } 0 \leq k \leq n+1$$

↻

" "	" "	I	can	can	a	can	" "	" "
<S>	<S>	PRO	PRO	PRO	PRO	PRO	<S>	<S>
		D	D	D	D	D		
		N	N	N	N	N		
		V	V	V	V	V		

1. initialisierung
2. Berechne die Backward Wk für PRO,D an position 4

Übung (Lösung): Trigramm-Backward Wk

Definition der Backward-Wahrscheinlichkeiten $\beta_{t'',t'}(k)$:

$$\beta_{t'',t'}(n+2) = \begin{cases} 1 & \text{falls } t'' = t' = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\beta_{t'',t'}(k) = \sum_{t \in T} p(t|t'',t') p(w_{k+1}|t) \beta_{t',t}(k+1) \quad \text{für } 0 \leq k \leq n+1$$

					k	k+1		
" "	" "		can	can	a	can	" "	" "
				t''	t'	t		
<s>	<s>	PRO	PRO	PRO	PRO	PRO	<s>	<s>
		D	D	D	D	D		
		N	N	N	N	N		
		V	V	V	V	V		

1. initialisierung

$$\text{bw}(\langle s \rangle, \langle s \rangle, 7) = 1$$

2. Berechne die Backward Wk für PRO,D an position 4

$$\begin{aligned} \text{bw}(\text{PRO}, \text{D}, 4) = & p(\text{PRO} | \text{PRO}, \text{D}) * p(\text{can} | \text{PRO}) * \text{bw}(\text{D}, \text{PRO}, 5) + \\ & p(\text{D} | \text{PRO}, \text{D}) * p(\text{can} | \text{D}) * \text{bw}(\text{D}, \text{D}, 5) + \\ & p(\text{N} | \text{PRO}, \text{D}) * p(\text{can} | \text{N}) * \text{bw}(\text{D}, \text{N}, 5) + \\ & p(\text{V} | \text{PRO}, \text{D}) * p(\text{can} | \text{V}) * \text{bw}(\text{D}, \text{V}, 5) \end{aligned}$$

Übung: Bigramm-Forward Wk

$$\alpha_t(0) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\alpha_t(k) = \sum_{t' \in T} \alpha_{t'}(k-1) p(t|t') p(w_k|t) \quad \text{für } 0 < k \leq n+1$$

↻

" "	I	can	can	a	can	" "
<s>	PRO	PRO	PRO	PRO	PRO	<s>
	D	D	D	D	D	
	N	N	N	N	N	
	V	V	V	V	V	

1. initialisierung
2. Berechne die Forward -Wk für D an position 4

Übung (Lösung) : Bigramm-Forward Wk

$$\alpha_t(0) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\alpha_t(k) = \sum_{t' \in T} \alpha_{t'}(k-1) p(t|t') p(w_k|t) \quad \text{für } 0 < k \leq n+1$$

↻

			k-1	k		
" "	I	can	can	a	can	" "
<s>	PRO	PRO	PRO	PRO	PRO	<s>
	D	D	D	D	D	
	N	N	N	N	N	
	V	V	V	V	V	
			t'	t		

1. initialisierung

$$\text{fw}(\langle s \rangle, 0) = 1$$

2. Berechne die Forward -Wk für D an position 4

$$\begin{aligned} \text{fw}(D, 4) = & \text{fw}(\text{PRO}, 3) * p(D | \text{PRO}) * p(a | D) + \\ & \text{fw}(D, 3) * p(D | D) * p(a | D) + \\ & \text{fw}(N, 3) * p(D | N) * p(a | D) + \\ & \text{fw}(V, 3) * p(D | V) * p(a | D) \end{aligned}$$

Übung: Bigram-Backward Wk

$$\beta_t(n+1) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\beta_t(k-1) = \sum_{t' \in T} p(t'|t) p(w_k|t') \beta_{t'}(k) \quad \text{für } 0 < k \leq n+1$$

↻

" "	I	can	can	a	can	" "
<s>	PRO	PRO	PRO	PRO	PRO	<s>
	D	D	D	D	D	
	N	N	N	N	N	
	V	V	V	V	V	

1. initialisierung
2. Berechne die Backward -Wk für D an position 4

Übung(Lösung): Bigram-Backward Wk

$$\beta_t(n+1) = \begin{cases} 1 & \text{falls } t = \langle s \rangle \\ 0 & \text{sonst} \end{cases}$$

$$\beta_t(k-1) = \sum_{t' \in T} p(t'|t) p(w_k|t') \beta_{t'}(k) \quad \text{für } 0 < k \leq n+1$$

				k-1	k	
" "	I	can	can	a	can	" "
<s>	PRO	PRO	PRO	PRO	PRO	<s>
	D	D	D	D _t	D	
	N	N	N	N	N	
	V	V	V	V	V	
					t'	

1. initialisierung

$$\text{bw}(\langle s \rangle, 0) = 1$$

2. Berechne die Backward -Wk für D an position 4

$$\begin{aligned} \text{bw}(\text{D}, 4) = & p(\text{PRO} | \text{D}) * p(\text{can} | \text{PRO}) * \text{bw}(\text{PRO}, 5) + \\ & p(\text{D} | \text{D}) * p(\text{can} | \text{D}) * \text{bw}(\text{D}, 5) + \\ & p(\text{N} | \text{D}) * p(\text{can} | \text{N}) * \text{bw}(\text{N}, 5) + \\ & p(\text{V} | \text{D}) * p(\text{can} | \text{V}) * \text{bw}(\text{V}, 5) \end{aligned}$$

Aufgabe 6) Wie ist beim Conditional Random Field die Wahrscheinlichkeit einer Tagfolge definiert? (4 Punkte)

↗

$$p(t_1^n | w_1^n) = \frac{1}{Z(w_1^n)} e^{\theta \cdot \sum_{i=1}^{n+1} f(t_{i-k}^i, w_1^n, i)}$$

↗